טופס הצעת מחקר

איה נאמן בהנחיית פרופ' שלומי דולב

<u>נושא המחקר</u>

העברת ידע ומיומנויות באינטראקציה לפי צורך (On-Demand) בין סוכנים.

<u>מוטיבציה ותיאור הבעיה</u>

בשימוש יומיומי בסוכנים, משתמשים מנהלים עשרות שיחות נפרדות (Sessions) או עוקבות מול אותו סוכן לאורך זמן (כגון פיתוח קוד מתמשך, ניהול פרויקט או מחקר). כיוון שמודלי שפה פועלים היום במודל חסר קונטקסט (Stateless), כל שיחה או פרויקט חדש מתחילים מ"לוח חלק". כתוצאה מכך, הסוכן שוכח לחלוטין מסקנות, תובנות ארכיטקטוניות, העדפות משתמש ותיקוני שגיאות שגובשו בעמל רב בשיחות קודמות (Zhao et al., 2026). כשל זה כופה על המשתמש לחזור על הנחיות והקשרים באופן מתיש, קוטע את רצף העבודה ומוביל לאובדן ידע מצטבר.

הפתרון הרווח היום של שרשור היסטוריית השיחות או הזרקת פרומטים ארוכים לתוך חלון ההקשר סובל משלוש מגבלות קריטיות:

1. הסחת דעת וירידה בדיוק: הגדלת חלון ההקשר מייצרת רעש שמפחית את דיוק המודל. מודלים סובלים מתופעת "Lost in the Middle", שבה מידע קריטי הנמצא במרכז ההקשר נשכח או מטושטש (Liu et al., 2024), וכן מגרר עיבוד המוריד את איכות החשיבה (Shi et al., 2023).
2. עלות חישובית וזמן תגובה (Latency): הזרקה פסיבית של עשרות אלפי טוקנים בכל פנייה מייצרת עומס חישובי כבד, מחיר כלכלי גבוה ואי-יכולת לגדול (Scalability) במערכות מרובות-סוכנים (Packer et al., 2023).
3. פסיביות של RAG קלאסי: מערכות אחזור סטטיות (Lewis et al., 2020) מביאות מקטעי טקסט בודדים ללא הבנת התהליך הפרוצדורלי או המיומנות הנדרשת, ואינן יודעות לסנן מידע שגוי או מיושן שהשתנה לאורך השיחות.

הפתרון המוצע במחקר משתמש במודל "מרוץ שליחים" והעברה אינטראקטיבית לפי צורך, הממשת את תפיסת ה-Educability של Valiant (2024a). הרץ הנוכחי (השיחה הנוכחית מול הסוכן) אינו אמור לסחוב על גבו את כל משא העבר של הרצים שקדמו לו (היסטוריית השיחות המלאה). באנלוגיה זאת, ה"מקל" המועבר מיד ליד מורכב אך ורק מהידע או מיומנות המזוקקת הנדרשת למקטע הנוכחי. במקום שהסוכן יוצף מראש במידע היסטורי, הוא מזהה נקודות אי ודאות או צרך במיומנות שהוא אינו מכיר ואז

יוזם שיח ממוקד (interactive dialogue) מול מופעי עבר. באמצעות שאלות הבהרה ודיאלוג קצר הוא מחלץ בדיוק את ה"מקל" הנדרש להשלמת המשימה. גישה זאת מאפשרת למידה מתמשכת (Zero-Retraining Continual Learning) השומרת על זיכרון ארוך טווח ללא אימון מחדש. ניסיונות ראשוניים מעידים על החיוניות והיתרון היחסי של העברת ידע ומיומנויות בשיטה זאת.

<u>מטרות, רקע מדעי וסקירת ספרות</u>

המחקר מוצע מבוסס על ארבעה אדני יסוד בספרות העדכנית בתחום מודלים שפה גדולים (LLMs) וסוכנים אוטונומיים:

- ארכיטקטורות זיכרון וניהול הקשר בסוכנים: מחקרים כגון Generative Agents (Park et al., 2023) ו-MemGPT (Packer et al., 2023) הניחו את התשתית לניהול זיכרון ארוך טווח ואפיזודי בסוכנים. לאחרונה (Episodic Memory, Pink, et al. 2025), הדגישו כי זיכרון אפיזודי הוא החולייה החסרה המאפשרת יכולת רציפה של סוכנים לאורך זמן.
- למידה מבוססת ניסיון ורפלקציה: טכניקות כמו Reflexion (Shinn et al., 2023) ו- Voyager (Wang et al., 2023) הראו כי סוכנים יכולים לשפר את ביצועיהם על ידי ניתוח טעויות עבר ואגירת מיומנויות חדשות בתוך הקשר הלמידה (In Context Learning), ללא צורך בעדכון משקלי המודל.
- אחזור ידע ותהליכי חשיבה: המחקר נשען על טכנולוגיית אחזור ידע Rag (Lewis et al., 2020) ועל ייצוג תהליכי חשיבה (Chain of thought, Wei et al., 2022). בנוסף, טכניקות ליצירת הוראות ושיפור ידע עצמי כגון Self-Instruct (Wang et al., 2023) ו- Evol-Instruct (Luo et al., 2024) מהוות בסיס להבנת אופן הניסוח וההעברה של מיומנויות מורכבות.
- הערכת ביצועי מודלים: לצורך מדידת איכות התשובות והיכולות הנרכשות, המחקר יתבסס ויורחב מתוך מתודולוגיית LLM-as-a-Judge והערכה מבוססת benchmarks (Zheng et al., 2023).
- תאוריית ה Educability-והוראה אינטראקטיבית: מחקריו התיאורטיים של וליאנט, מניחים את התשתית למושג ה-Educability (Valiant, 2024a; Valiant, 2024b), היכולת של סוכן חישובי לרכוש מיומנויות חדשות דרך הוראה ותקשורת ממוקדת (Instruction & Dialogue) ולא רק דרך אימון סטטיסטי מחדש על נתוני עתק. תפיסה זו מספקת את הצידוק התיאורטי למעבר מלמידת מכונה קלאסית לתהליכי תיווך והעברת ידע אינטראקטיביים בין סוכנים.

הפער המדעי וחידוש המחקר

למרות ההתקדמות הניכרת בתחומים אלו, קיימים מספר פערים מרכזיים בספרות שהמחקר הנוכחי בא לפתור:

1. מעבר מאחזור מידע סטטי להעברה אינטראקטיבית לפי צורך (Educability מיושמת): מנגנוני RAG (Lewis et al., 2020) ומודלי זיכרון קיים (Packer et al., 2023) פועלים כהזרקת תוכן חד כיוונית ופסיבית. המחקר מממש את חזון הEducability של וליאנט (Valiant, 2024a) ברמת הסוכנים: במקום אחזור פסיבי, הסוכן מנהל דיאלוג ממוקד ודו-כיווני מול מופעי העבר רק כשהוא נתקל בחוסר וודאות, ובכך "מתחנך" בזמן אמת לביצוע המשימה.
2. העברת ידע חוצה שיחות (Cross-conversational Skill Transfer): שיטות רפלקציה קיימות (Shinn et al., 2023; Wang et al., 2023) מדגימות למידה בתוך סביבה סגורה או משימה רציפה אחת. מחקר זה מציע מנגנון להעברה בין-שיחתית (Pairwise & Multi-History Transfer) המאפשר למודל ללמוד משיחות עבר שונות וליישם את המסקנות על תרחישים חדשים לחלוטין. המחקר יעצור סוכנים שמגיעים לרף של 70% מהקונטקסט המקסימלי שלהם על מנת לשמור את השיחה מדגרדציה באיכות התשובות ויכולת הסריקה על מנת לענות לשאלות מממוקדות.
3. אלגוריתם אחזור מרובה-פרמטרים: במקום להסתמך אך ורק על קרבה סמנטית (Embedding Similarity) כמקובל בספרות, פרויקט זה מפתח שיטת ניקוד חדשנית המשקללת ארבעה גורמים: קרבה סמנטית, הצלחה היסטורית של השיחה, התאמת מיומנויות נדרשות, וזמן הביצוע (Recency).
4. מטריקת שימור מיומנויות ללא אימון מחדש: המחקר יציע מטריקה חדשה להערכת אפקטיביות הבלעת המיומנויות ושימורן לאורך זמן (Zero-Retraining Continual Learning), תוך מדידת מניעת דעיכת ביצועים בשיחות עתידיות.

מטרות המחקר

המטרה המרכזית הינה פיתוח מנגנון אינטראקטיבי לפי צורך להעברת ידע ומיומנויות בין מופעי בינה מלאכותית ברמת השיחות (Sessions), הפרויקטים והסוכנים להשגת למידה מתמשכת ללא אימון מחדש. המטרות הספציפיות כוללות:

1. אפיון טופולוגיות הידע ומנגנון הזיהוי לפי צורך: סיווג סוגי הידע (מיומנויות פרוצדורליות, העדפות משתמש ותיקוני שגיאות) והגדרת טריגרים אוטומטיים המזהים בזמן אמת נקודות חוסר-ודאות

במופע הפעיל. המטרות הן ליזום אינטראקציה רק בעת צורך קונקרטי ולמנוע הצפה של חלון ההקשר.

2. תכנון סכמות העברה ("מודל מרוץ השליחים"): תכנון ומדידה של העברת מיומנויות בין שיחות, תוך השוואה אמפירית בין העברה אינטרקטיבית ומזוקקת באמצעות דיאלוג ממוקד, לבין הזרקה פסיבית וסטטית של פרומטים ארוכים (Context Injection/Prompt stuffing).
3. פיתוח מנגנון דירוג ואחזור היסטורי: פיתוח אלגוריתם הניקוד המרוכב המתחשב בדמיון סמנטי, התאמת מיומנויות, מדד הצלחה היסטורי וזמן הביצוע (Recency).
4. סינתזה מרובת-מקורות (Multi-History Aggregation): בחינת אפקטיביות השילוב של מסקנות ממספר שיחות עבר במקביל תוך מניעת סתירות, לעומת הסתמכות על שיחת עבר בודדת בעלת ציון הניקוד הגבוה ביותר.
5. פיתוח מטריקת הערכה ללמידה מתמשכת: הגדרת מטריקה כמותית למדידת יעילות הסוכן, שיעור שימור המיומנויות (Skill Retention Rate) ועמידות בפני דעיכת ביצועים לאורך זמן ללא עדכון משקלים.

<u>מתודולוגיה ושיטות מחקר</u>

1. סקירת ספרות מקיפה:
   a. מיפוי טכניקות קיימות לזיקוק ידע (Knowledge Distillation) והעברת יכולות בין סוכנים.
   b. זיהוי מגבלות בארכיטקטורות זיכרון משלימות למודלי שיחה ברמת השיחה הבודדת והרב-שיחתית.
2. ארכיטקטורה ותכנון הסכמה:
   a. עיצוב סכמת ייצוג יעילה לשמירת ידע ומיומנויות, המאגדת תיעוד פרוצדורלי, נתיבי חשיבה (Chain-of-Thought), תיקוני שגיאות וסיכומים מבניים תוך התייחסות לגודל הקונטקסט המקסימלי שמודל יכול להכיל.
   b. אפיון דרגת האקספרסיביות (Expressiveness) של הסכמה והקמת מאגר נתונים מבוסס שיחות ללמידה ולהערכה.
3. יישום ניסויי ומימוש המערכת:
   a. פיתוח אב-טיפוס המשווה בין הזרקה אוטומטית של הקשר לבין מנגנון שאלות-ותשובות אינטראקטיבי בין סוכנים.
   b. ביצוע ניסויים בהגדרות Zero-Shot ו-Few-Shot כקו בסיס (Baseline), לצד דירוג שיחות עבר לפי מידת אפקטיביות העברת המיומנות.

4. ניתוח, הערכה ומדידה:
   a. מדידת ביצועי הסוכן במשימה הראשונית ומעקב לאורך זמן אחר שימור היכולות (Skill Retention) בין שיחות עוקבות.
   b. הערכת הדיוק, הרלוונטיות והאפקטיביות של השיח האינטראקטיבי בפתרון הבעיה הנוכחית באמצעות מתודולוגיית LLM-as-a-Judge.
5. סיכום ותיעוד מחקרי:
   a. תיעוד פורמלי של האלגוריתמים, ייצוגי הנתונים וסכמות הלמידה.
   b. ניתוח סטטיסטי של התוצאות, כתיבת דוח מחקר מקיף והכנת מאמר אקדמי לפרסום.

<u>רשימת מקורות ראשונית</u>

1. Park, Joon Sung, et al. "Generative agents: Interactive simulacra of human behavior." *Proceedings of the 36th annual acm symposium on user interface software and technology*. 2023.
2. Packer, Charles, et al. "MemGPT: towards LLMs as operating systems." (2023).
3. Shi, Freda, et al. "Large language models can be easily distracted by irrelevant context." *International conference on machine learning*. PMLR, 2023.
4. Shinn, Noah, et al. "Reflexion: Language agents with verbal reinforcement learning." *Advances in neural information processing systems* 36 (2023): 8634-8652.
5. Lewis, Patrick, et al. "Retrieval-augmented generation for knowledge-intensive nlp tasks." *Advances in neural information processing systems* 33 (2020): 9459-9474.
6. Wang, Guanzhi, et al. "Voyager: An open-ended embodied agent with large language models." *arXiv preprint arXiv:2305.16291* (2023).
7. Wei, Jason, et al. "Chain-of-thought prompting elicits reasoning in large language models." *Advances in neural information processing systems* 35 (2022): 24824-24837.
8. Wang, Yizhong, et al. "Self-instruct: Aligning language models with self-generated instructions." *Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers)*. 2023.
9. Pink, Mathis, et al. "Position: Episodic memory is the missing piece for long-term llm agents." *arXiv preprint arXiv:2502.06975* (2025).

10. Liu, Nelson F., et al. "Lost in the middle: How language models use long contexts." *Transactions of the association for computational linguistics* 12 (2024): 157-173.
11. Luo, Ziyang, et al. "Wizardcoder: Empowering code large language models with evol-instruct." *International Conference on Learning Representations*. Vol. 2024. 2024.
12. Valiant, L. (2024a). The Importance of Being Educable. Princeton University Press.
13. Valiant, L. (2024b). Educability. arXiv preprint arXiv:2412.09480.
14. Zheng, Lianmin, et al. "Judging llm-as-a-judge with mt-bench and chatbot arena." *Advances in neural information processing systems* 36 (2023): 46595-46623.
15. Zhao, Wayne Xin, et al. "A survey of large language models." *Frontiers of Computer Science* 20.12 (2026): 2012627.

הערה: רשימת המקורות תורחב ותעודכן במהלך המחקר בהתאם לממצאים ולכיוונים חדשים שיתגלו.